

Detección de anomalías mediante forecasting con Prophet

Arnau Sastre

[linkedin.com/in/arnausastre](https://www.linkedin.com/in/arnausastre)

September 9, 2025

Abstract

Este artículo presenta un sistema de detección de anomalías basado en modelos de forecasting con **Prophet**, orientado al análisis automatizado de KPIs en contextos empresariales. Se muestra el enfoque metodológico, la formulación matemática del modelo, las métricas obtenidas, y su aplicabilidad práctica en distintos entornos como Ecommerce, Operaciones o Tecnología.

1 Introducción

La detección temprana de comportamientos anómalos en los datos de negocio permite anticiparse a posibles fallos, optimizar la toma de decisiones y automatizar la supervisión de indicadores clave de rendimiento (KPIs). En este trabajo, se desarrolla un sistema de detección de anomalías utilizando el modelo de series temporales **Prophet**, capaz de adaptarse a estacionalidades y tendencias propias de los datos empresariales.

2 Definición de anomalía

Una **anomalía** se define como una desviación significativa respecto al comportamiento esperado de una variable temporal. Sea y_t la observación real en el tiempo t y \hat{y}_t el valor predicho, una anomalía se detecta si:

$$|y_t - \hat{y}_t| > \delta$$

donde δ es un umbral definido a partir de la desviación estándar de los errores o mediante intervalos de confianza.

3 Modelo utilizado: Prophet

Prophet es un modelo aditivo que descompone una serie temporal en componentes interpretable de tendencia, estacionalidad y festivos. Formalmente, el modelo se expresa como:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

donde:

- $g(t)$: tendencia no lineal
- $s(t)$: componente estacional (semanal, anual, etc.)
- $h(t)$: efecto de festivos (opcional)

- ϵ_t : error aleatorio

Prophet permite detectar puntos fuera del intervalo de predicción como posibles anomalías.

4 Métricas de evaluación

El sistema fue evaluado mediante las siguientes métricas:

MAE (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

RMSE (Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

MAPE (Mean Absolute Percentage Error)

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

5 Resultados

Tras aplicar el modelo a una serie temporal de ejemplo, se obtuvieron los siguientes resultados:

- MAE: 2.91
- RMSE: 3.44
- MAPE: 2.83%
- Anomalías detectadas automáticamente: 14

Las predicciones fueron visualizadas junto con los intervalos de confianza para facilitar la identificación de anomalías.

6 Aplicación empresarial

El sistema es parametrizable y adaptable a cualquier KPI temporal. Algunas aplicaciones prácticas incluyen:

- Ecommerce: detección de caídas de ventas o picos de tráfico inesperados
- Operaciones: anomalías en inventario, producción o tiempos de entrega
- Tecnología: aumento inusual de errores en backend o desplomes en el uso de la aplicación

La solución puede integrarse en dashboards con herramientas como Power BI, Looker, o incluso conectarse a sistemas de alertas automáticas.

7 Conclusiones

Se ha desarrollado un sistema eficiente para la detección automatizada de anomalías utilizando Prophet. Las métricas obtenidas demuestran una capacidad predictiva robusta, con posibilidad de ser desplegado en contextos reales de negocio.

Contacto

Si te interesa implementar una solución similar en tu empresa, no dudes en escribirme a través de **LinkedIn** o **Malt**. También puedes ver otros proyectos técnicos en mi **GitHub**.