

Forecasting de Ocupación con Deep Learning (LSTM)

Arnau Sastre

[linkedin.com/in/arnausastre](https://www.linkedin.com/in/arnausastre)

September 9, 2025

Abstract

Este documento presenta un sistema de predicción de ocupación diaria basado en redes neuronales recurrentes (LSTM). Se aborda su aplicación práctica en contextos donde anticipar la demanda es crítico, como hoteles, gimnasios, aerolíneas o restaurantes. El modelo permite detectar automáticamente días con alta demanda, facilitando decisiones en planificación operativa y optimización de ingresos. Se describen la metodología utilizada, métricas de evaluación, visualizaciones relevantes y posibles extensiones.

1 Introducción

La capacidad de anticipar la demanda diaria es clave en sectores donde los recursos físicos o humanos son limitados. Contar con un sistema automatizado que prediga la ocupación futura y detecte días con alta demanda permite optimizar personal, precios y operaciones.

Este proyecto desarrolla un modelo basado en **LSTM** (Long Short-Term Memory), una arquitectura de red neuronal recurrente adecuada para modelar dependencias temporales, aplicado a series temporales de ocupación.

2 Objetivo

El objetivo principal es predecir la ocupación diaria a partir de datos históricos e identificar automáticamente días que superen un umbral de alta demanda. Estos picos pueden activar acciones como:

- Refuerzo de personal operativo
- Activación de campañas específicas
- Aplicación de precios dinámicos (revenue management)

3 Generación de datos simulados

Se simula una serie temporal de ocupación con las siguientes características:

- Tendencia creciente
- Estacionalidad semanal (ciclos de 7 días)

- Estacionalidad mensual (ciclos de 30 días)
- Ruido aleatorio controlado

La ocupación simulada y_t en el tiempo t puede expresarse como:

$$y_t = \text{trend}(t) + \text{seasonal}_{\text{week}}(t) + \text{seasonal}_{\text{month}}(t) + \epsilon_t$$

4 Modelo utilizado: LSTM

Se entrena un modelo secuencial basado en LSTM utilizando TensorFlow/Keras. El modelo recibe secuencias pasadas de ocupación y predice el siguiente valor.

Preprocesamiento

- Normalización de los datos con `MinMaxScaler`
- División en secuencias temporales para entrenamiento

Arquitectura

- Capa LSTM con memoria a corto y largo plazo
- Capa densa de salida con activación lineal

Entrenamiento

- Optimización con Adam
- Función de pérdida: error cuadrático medio
- Validación cruzada temporal

5 Detección de anomalías

Se define como **día de alta demanda** aquel cuya ocupación predicha supera el percentil 95 de la distribución:

$$\hat{y}_t > P_{95}(\hat{y})$$

donde \hat{y}_t es la predicción y P_{95} representa el percentil 95.

6 Métricas de evaluación

El rendimiento del modelo se evaluó con las siguientes métricas:

MAE (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| = 4.83$$

RMSE (Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} = 5.93$$

MAPE (Mean Absolute Percentage Error)

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| = 9.71\%$$

7 Resultados

El modelo fue capaz de capturar la dinámica de la ocupación diaria y detectar automáticamente 36 días con ocupación en el top 5% de la serie predicha.

- RMSE: 5.93
- MAE: 4.83
- MAPE: 9.71%
- Días de alta demanda detectados: 36

8 Visualizaciones clave

Se generaron las siguientes visualizaciones para interpretar el comportamiento del modelo:

- Ocupación real vs. predicha
- Análisis de residuos
- Dispersión entre predicciones y valores reales
- Promedio de ocupación por día de la semana (heatmap)

9 Casos de uso reales

- Hoteles: previsión de reservas por día
- Gimnasios: anticipación de demanda en clases
- Aerolíneas low-cost: predicción por vuelo
- Restaurantes: gestión de turnos en días pico
- Coworkings: previsión de ocupación por espacio

10 Aplicación práctica

El sistema puede integrarse en flujos reales mediante:

- Dashboards en Power BI o Looker
- Notebooks en Jupyter o Google Colab
- Sistemas de alerta para planificación operativa

11 Conclusiones

Se ha desarrollado un sistema robusto de forecasting de ocupación diaria utilizando LSTM. La capacidad de detección temprana de días con alta demanda permite tomar decisiones más informadas en la planificación operativa y la estrategia comercial. El modelo es fácilmente adaptable a datos reales y sectores distintos.

Contacto

Si te interesa implementar una solución similar en tu empresa o necesitas ayuda en proyectos de forecasting, optimización o análisis de datos, puedes escribirme por **LinkedIn** o **Malt**. También puedes consultar otros proyectos técnicos en mi **GitHub**.